PROJETO FINAL
INDIVIDUAL

Mineração de Dados com apoio de LLM via API



Um projeto para aplicar técnicas estudadas na disciplina e, somente depois, usar uma LLM para interpretar e comunicar os resultados.

O que este projeto pretende avaliar?

O objetivo não é construir um sistema grande. É demonstrar que você sabe percorrer um pequeno processo de Mineração de Dados.

1. Preparar os dados

Compreender a base, verificar problemas de qualidade, selecionar atributos e aplicar transformações quando necessário.

2. Produzir um resultado

Aplicar uma técnica estudada, gerar evidências objetivas e organizar os principais achados.

3. Usar a LLM depois

Enviar à LLM um resumo dos resultados por meio de API e avaliar criticamente a interpretação produzida.

Regra central do trabalho

A LLM não substitui a mineração. Primeiro o Python produz o resultado. Depois a LLM ajuda a interpretar, sintetizar ou comunicar o que foi encontrado.

Projeto Final Individual — Mineração de Dados com LLM via API

Objetivo: aplicar técnicas estudadas na disciplina e usar uma LLM para interpretar os resultados

1 Escolha do dataset



Selecionar um dataset tabular (ex.: Kaggle)

2 Entendimento dos dados



Identificar atributos, tamanho da base e pergunta de análise

3 Preparação dos dados



- valores ausentes
- outliers
- normalização/ padronização
- seleção de atributos

4 Mineração / Análise



Aplicar pelo menos uma técnica estudada

- **similaridade e distância**
- **outliers**
- **engenharia de atributos**

5 Resultado estruturado



Gerar tabelas, métricas e um resumo objetivo dos achados

6 LLM via API



Enviar o resumo para uma API (ChatGPT, Gemini, Claude, Ollama etc.)

A LLM interpreta, resume e sugere explicações

7 Conclusão do aluno



Avaliar a resposta da LLM e apresentar conclusões próprias

Entregas

1. código em Python
2. dataset ou link
3. resultado da análise
4. prompt + resposta da LLM
5. conclusão curta

Visão geral do Projeto Final Individual.

Importante: a LLM não substitui a mineração. Ela entra depois da análise para interpretar os resultados.

O papel da LLM no projeto

A inteligência generativa entra como uma camada de interpretação, não como atalho para pular a disciplina.

Uso adequado

✓ O Python trata os dados
✓ A técnica de mineração produz resultados
✓ O aluno monta um resumo estruturado
✓ A API envia o resumo para a LLM
✓ A LLM interpreta os achados
✓ O aluno verifica se a resposta faz sentido

Uso inadequado

✕ Enviar o CSV inteiro para a LLM
✕ Pedir faça toda a mineração
✕ Copiar a resposta sem verificar os dados
✕ Inventar resultados não gerados pelo código
✕ Transformar a API no objetivo principal do projeto

Escopo pensado para duas semanas

O projeto é individual e deve ser pequeno o suficiente para ser concluído sem competir com todas as outras atividades do semestre.

ESCOPO MÍNIMO

- 1 dataset tabular público
- 1 pergunta principal de análise
- preparação objetiva dos dados
- pelo menos 1 técnica de análise/mineração já estudada
- 1 integração simples com LLM via API
- 1 conclusão curta e crítica

O projeto NÃO precisa ter

ibanco de dados, dashboard, RAG, agentes ou múltiplos modelos.

Sugestão de tamanho

- Dataset: algumas centenas a poucos milhares de linhas
- Atributos úteis: aproximadamente 5 a 20
- Código: Notebook ou .py organizado
- Apresentação: curta e objetiva

Etapa 1 — Escolha do dataset

O aluno pode escolher um dataset público, por exemplo no Kaggle, desde que seja adequado ao tempo disponível.

Prefira

- arquivo CSV ou tabela simples
- atributos compreensíveis
- problema fácil de explicar
- base pequena ou média
- dados sem informações pessoais identificáveis
- tema de interesse do aluno

Evite

- imagens, áudio ou vídeo
- centenas de colunas
- arquivos muito grandes
- bases que dependam de dezenas de arquivos
- datasets cujo significado dos atributos seja desconhecido

Antes de começar

Responda:

1. O que cada linha representa?
2. Quais atributos são úteis?
3. Qual pergunta quero investigar?
4. Que técnica estudada pode ajudar a responder essa pergunta?

Ideias de temas para o dataset

O tema pode variar. O importante é que os dados permitam uma pergunta clara e uma análise coerente.

Clientes e vendas

frequência de compra, ticket, renda, idade, produtos

Educação

notas, frequência, horas de estudo, entregas, participação

Imóveis

preço, área, quartos, localização codificada, idade do imóvel

Veículos

preço, quilometragem, consumo, potência, ano

Energia

consumo por horário, período, equipamento ou unidade

Esportes

estatísticas de atletas, desempenho, frequência, resultados

Quais conteúdos da disciplina podem aparecer?

Não é necessário usar tudo. O aluno deve escolher técnicas que façam sentido para o dataset e para a pergunta formulada.

Qualidade dos dados	ausentes, duplicidades, inconsistências
Outliers	IQR, Z-score, Isolation Forest
Transformações	normalização, padronização, escalonamento
Engenharia de atributos	criação de representações úteis
Similaridade e distância	distância Euclidiana, proximidade entre registros
Análise com Pandas	filtros, agregações, estatísticas e tabelas

Recomendação: combine pelo menos três conteúdos da disciplina, sendo um deles uma técnica de análise/mineração.

Exemplo de Projeto Final — Análise de Clientes com LLM via API

Ideia de trabalho: usar um dataset tabular do Kaggle para identificar perfis semelhantes, possíveis casos atípicos e pedir à LLM uma interpretação dos resultados.

1. Escolha do dataset



Exemplo: base de clientes do Kaggle

colunas possíveis: idade, renda, compras, ticket médio

2. Entendimento da base



Ler o CSV, observar tipos de dados, tamanho da base e significado dos atributos

3. Preparação dos dados



- verificar valores ausentes
- observar outliers
- normalizar/ padronizar
- selecionar atributos

4. Mineração / análise



Aplicar técnicas estudadas

similaridade e distância

outliers

engenharia de atributos

Ex.: encontrar clientes mais semelhantes e mais diferentes

5. Resultado estruturado



Gerar um resumo objetivo

- clientes mais próximos
- registros atípicos
- principais características

6. Envio para a LLM



Usar API (ChatGPT, Gemini, Claude, Ollama etc.)

Prompt: Interprete os resultados encontrados e descreva os perfis observados sem inventar dados.

7. Resposta da LLM



A LLM descreve perfis, resume padrões e sugere interpretações

- perfil de clientes
- leitura dos achados
- texto explicativo

8. Conclusão do aluno



Avaliar se a resposta da LLM faz sentido e apresentar conclusões próprias

Entregas

1. código em Python
2. dataset ou link do Kaggle
3. resultado da análise
4. prompt + resposta da LLM
5. conclusão curta

Exemplo de pergunta de projeto

"Quais clientes apresentam perfis mais semelhantes e quais registros parecem mais diferentes do comportamento geral?"

A LLM entra depois da análise para interpretar os resultados, não para substituir a mineração.

Exemplo de sequência para um projeto de análise de clientes.

Exemplo de projeto: clientes

O projeto precisa de uma pergunta específica, não apenas “analisar o dataset”.

Pergunta exemplo: Quais clientes apresentam perfis mais semelhantes e quais registros se afastam mais do comportamento geral?



A pergunta orienta as decisões: quais atributos usar, que transformação aplicar, que resultado produzir e o que enviar à LLM.

Projeto: Visão Geral

O que é?

Um projeto prático e individual em que você escolhe um dataset público, aplica técnicas de Mineração de Dados e utiliza uma LLM (via API) para interpretar os resultados.

Objetivo

Transformar dados em informação e obter uma interpretação apoiada por IA.

Principais Entregas

- Código (Notebook ou .py)
- Dataset ou link do Kaggle
- Resultados da análise/mineração
- Integração com API de uma LLM
- Conclusão (curta)

Exemplo de Projeto: Análise de Clientes

Pergunta de exemplo: *"Quais são os perfis de clientes mais semelhantes e existem clientes com comportamento muito diferente (outliers)?"*

1 Escolha do Dataset

kaggle

Selecionar um dataset público (ex.: clientes, vendas, veículos, imóveis etc.).

2 Entendimento e Preparação

- Carregar os dados
- Explorar (dimensões, tipos)
- Tratar valores ausentes
- Remover inconsistências
- Selecionar atributos

3 Transformação

- Normalizar ou padronizar os atributos
- (Opcional) Criar novos atributos

4 Mineração / Análise

- Aplicar uma técnica estudada (ex.: cálculo de distância/ similaridade, detecção de outliers)
- Obter os principais resultados

5 Resumo dos Resultados

Cliente A	Cliente B	Distância
102	487	0,12
044	732	2,78
...	...	...

- Organizar os achados (pares mais semelhantes, registros mais diferentes, quantidade de outliers etc.).

6 Integração com a LLM (via API)

- Enviar um resumo dos resultados para a API (ex.: OpenAI, Gemini, Claude).
- Solicitar uma interpretação dos padrões encontrados.

7 Interpretação e Conclusão

- Analisar a resposta da LLM.
- Verificar se a interpretação faz sentido com os dados.
- Concluir com os principais insights obtidos.

Resultado Esperado

- ✓ Dados preparados
- ✓ Análise de Mineração
- ✓ Interpretação da LLM
- ✓ Conclusão sobre o problema investigado

Fluxo detalhado de um exemplo concreto de projeto.

O que deve chegar à LLM?

A LLM deve receber um resultado organizado pelo código, e não o problema inteiro “cru”.

Exemplo de resumo gerado pelo Python

Dataset: clientes
Registros analisados: 850

Menor distância encontrada:
Cliente 102 ↔ Cliente 487 = 0,12

Registros mais afastados:
Cliente 44 e Cliente 732

Outliers detectados: 12

Características predominantes:
• clientes próximos possuem frequência e ticket semelhantes
• alguns registros apresentam renda e frequência muito diferentes da maioria

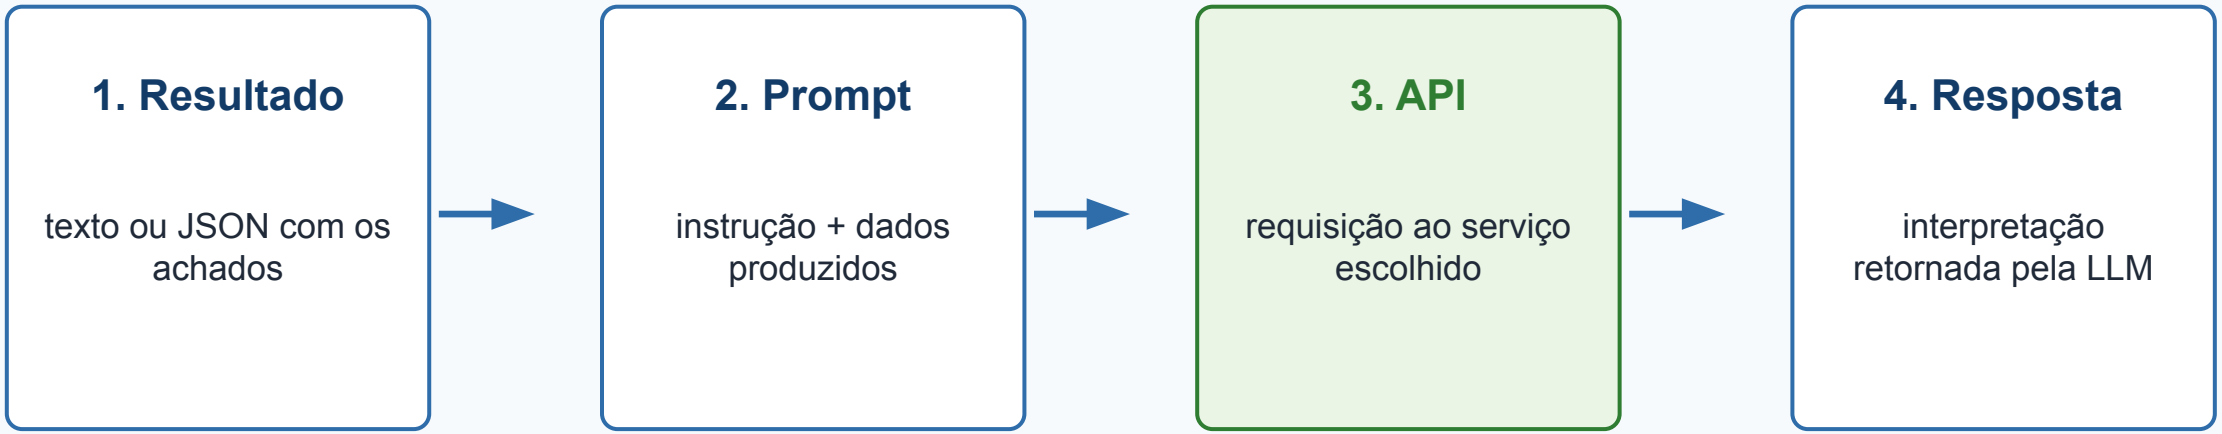
O que a LLM pode fazer com isso

• descrever os padrões em linguagem natural
• organizar os achados por importância
• sugerir interpretações plausíveis
• gerar um pequeno resumo executivo
• apontar perguntas adicionais

A resposta deve permanecer limitada às evidências fornecidas pelo programa.

Integração com uma LLM via API

A integração pode ser simples: montar um prompt, enviar o resumo e receber uma resposta textual.



Um bom prompt também faz parte do projeto

É necessário dizer à LLM o que fazer com o resultado e limitar a possibilidade de invenção.

Exemplo de prompt

Você receberá resultados produzidos por uma análise de Mineração de Dados. Interprete somente as informações fornecidas. Não invente valores. Destaque os principais padrões, explique os registros mais semelhantes e os casos mais diferentes e produza uma conclusão curta em linguagem clara.

Contexto

diga o que os dados representam

Limites

peça para não inventar dados

Saída

defina o formato esperado

A última palavra é do analista

A resposta da LLM não deve ser aceita automaticamente. Ela precisa ser confrontada com os resultados reais do código.

1. A LLM descreveu corretamente os valores e padrões?
2. Ela afirmou algo que não estava no resumo?
3. A interpretação é coerente com o contexto do dataset?
4. Existe outra explicação possível para o resultado?
5. Qual conclusão o próprio analista sustenta com os dados?

O que deverá ser entregue?

A entrega é enxuta, mas deve permitir que o projeto seja entendido e reproduzido.

1	**Código**	Notebook (.ipynb) ou arquivo .py organizado
2	**Dataset**	arquivo utilizado ou link para a fonte pública
3	**Resultados**	tabelas, métricas ou saídas produzidas pela análise
4	**Integração LLM**	trecho da chamada à API, prompt e resposta
5	**Conclusão**	texto curto com avaliação crítica dos achados

Não entregar chaves de API.

Sugestão de critérios de avaliação

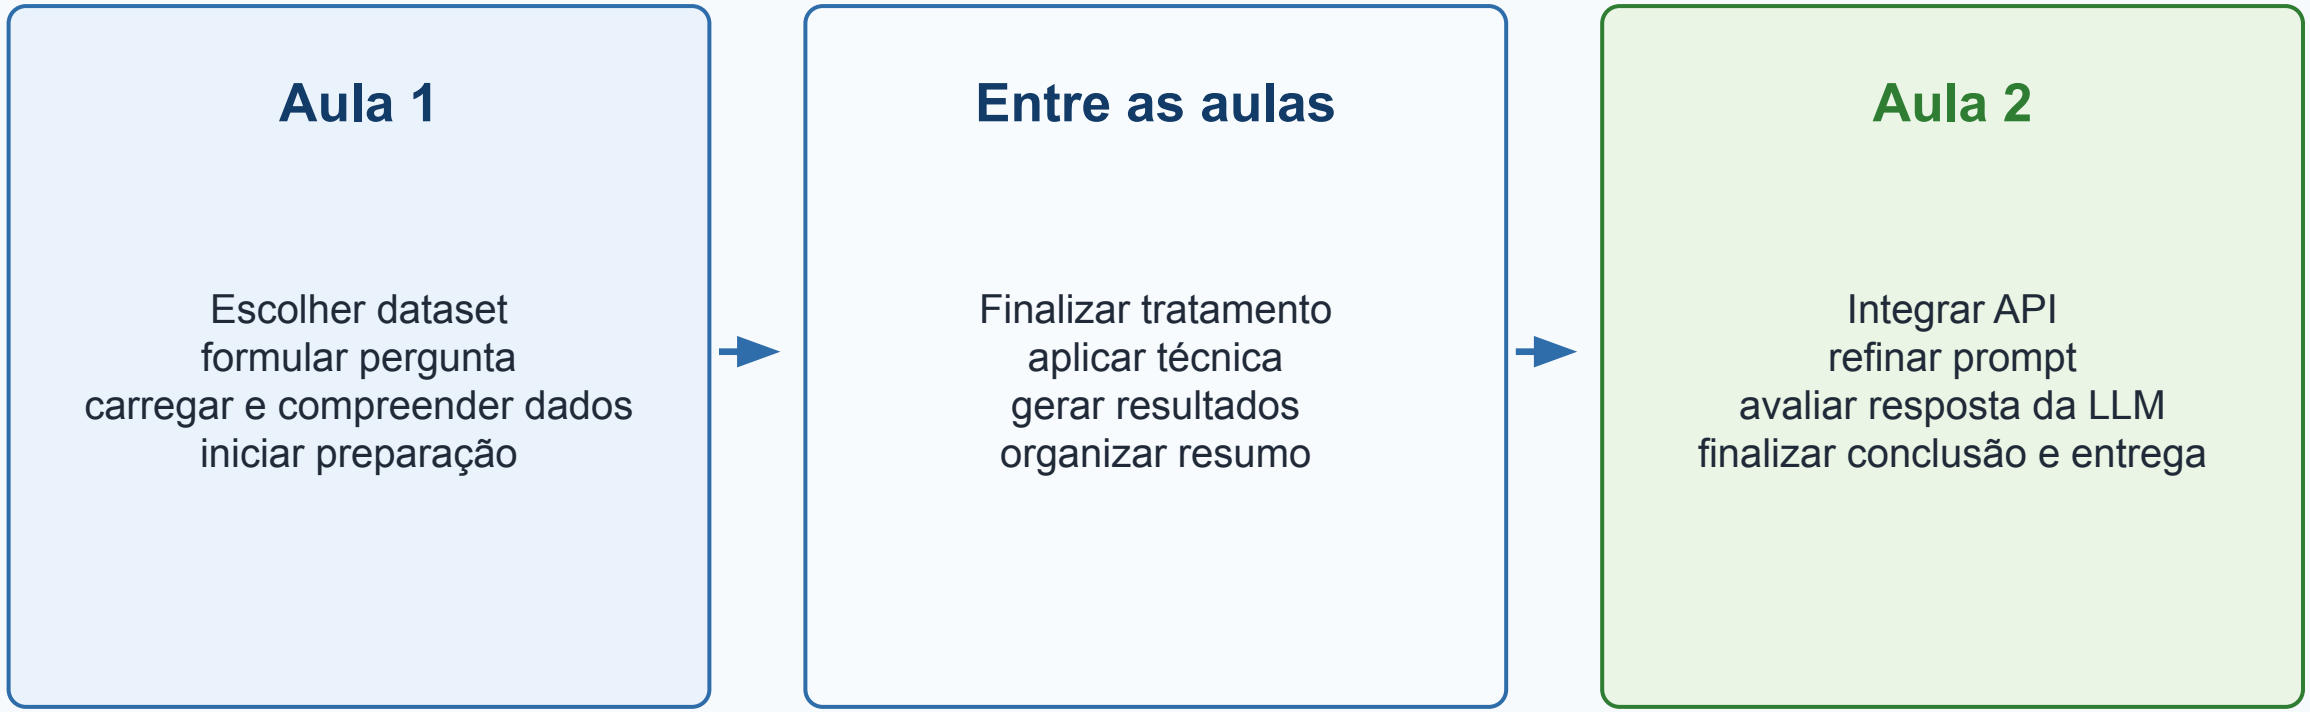
O foco da nota está no processo e na coerência das decisões, não na sofisticação do software.



Total: 100 pontos

Cronograma sugerido

Duas aulas de desenvolvimento, com trabalho individual entre elas.



Checklist antes de entregar

Use esta lista para conferir se o projeto está realmente completo.

- [ ] Escolhi um dataset adequado ao prazo
- [ ] Expliquei a pergunta que quero investigar
- [ ] Verifiquei qualidade e tipos dos dados
- [ ] Justifiquei atributos e transformações
- [ ] Apliquei uma técnica estudada
- [ ] Gerei resultados objetivos no Python
- [ ] Enviei somente o resumo necessário à LLM
- [ ] Registrei prompt e resposta
- [ ] Escrevi minha própria conclusão crítica

A ideia central do projeto

DADOS → **MINERAÇÃO** → **LLM** → **CONCLUSÃO**

A técnica de Mineração de Dados produz evidências. A LLM ajuda a interpretar. O aluno é responsável por avaliar e sustentar a conclusão.